

Politechnika Rzeszowska

Wydział Matematyki i Fizyki Stosowanej

Zakład Systemów Złożonych

Sprawozdanie z projektu

Wielowymiarowa Analiza Danych

Analiza danych przestępczości miasta Chicago

Autorzy: Maciej Gilecki

Wioletta Grabias

Numer indeksu: 173142 176800

Kierunek: Inżynieria i analiza danych

Rok akademicki: 2025/2026

Prowadzący: dr inż. Paweł Dymora

Rzeszów, 2 czerwca 2026

Spis treści

1	Cel projektu	2
2	Opis danych	2
3	ETL	4
3.1	ETL 1 – DimDate	5
3.2	ETL 2 – DimLocation	6
3.3	ETL 3 – DimCrimeType	7
3.4	ETL 4 – DimLocationType	8
3.5	Execute SQL Task – finalny przepływ danych	10
4	Kostka OLAP	11
4.1	Hierarchie	13
5	Scenariusze – KPI	15
5.1	Scenariusz 1 – Arrest Effectiveness	15
5.2	Scenariusz 2 – Domestic Violence Watch	15
5.3	Scenariusz 3 – Crime Volume Annual	16
5.4	Scenariusz 4 – Theft Rate / Theft Dominance	17
5.5	Scenariusz 5 – Daily Crime Load	18
6	Data Mining	19
6.1	Drzewo decyzyjne (DT_Arrest)	19
6.2	Sieć neuronowa (NN_Arrest)	21
6.3	Naive Bayes (NB_Arrest)	21
6.4	Klastrowanie (Clustering_Crime)	23
6.5	Porównanie modeli	24
7	Model tabelaryczny (SSAS Tabular)	25
8	Wizualizacja danych – Power BI	26
8.1	Raport 1 – KPI Dashboard	28
8.2	Raport 2 – Geografia przestępczości	28
8.3	Raport 3 – Analiza relacyjna (import z hurtowni)	29
9	Podsumowanie	31

1 Cel projektu

Celem projektu jest implementacja kompleksowego rozwiązania wielowymiarowej analizy danych dla zbioru *Chicago Crime*, obejmującego pełen cykl przetwarzania danych: od procesu ETL, przez budowę hurtowni danych i kostki OLAP, po analizę z wykorzystaniem algorytmów Data Mining oraz wizualizację wyników w narzędziu Power BI.

W ramach projektu zrealizowano następujące zadania:

- Implementacja 5 przepływów ETL w środowisku SQL Server Integration Services (SSIS)
- Zaprojektowanie i wdrożenie hurtowni danych w schemacie gwiazdy
- Budowa kostki OLAP w środowisku SQL Server Analysis Services (SSAS) Multidimensional
- Utworzenie 5 wskaźników KPI z miarami obliczanymi (Calculated Members)
- Implementacja 4 modeli Data Mining
- Wizualizacja wyników w Power BI Desktop (połączenie Live do SSAS oraz import z hurtowni relacyjnej)

Wykorzystane oprogramowanie: Microsoft SQL Server 2019 Developer, Visual Studio 2017 z dodatkami SSDT, Microsoft Power BI Desktop.

2 Opis danych

Zbiór danych *Chicago Crime* pochodzi z oficjalnego portalu danych miasta Chicago (<https://data.cityofchicago.org/>) i zawiera szczegółowe informacje o zarejestrowanych przestępstwach od roku 2001 do dnia dzisiejszego. Oryginalny zbiór liczy ponad 8 milionów rekordów; na potrzeby projektu wykorzystano próbkę 1 miliona wierszy.


Opis kolumn źródłowych

Kolumna	Opis
ID	Unikalny identyfikator zdarzenia
Date	Data i godzina zdarzenia
Primary Type	Główny typ przestępstwa (THEFT, BATTERY, NARCOTICS...)
Description	Szczegółowy opis przestępstwa
Location Description	Typ lokalizacji (STREET, RESIDENCE, APARTMENT...)
Arrest	Czy doszło do aresztowania (BIT)
Domestic	Czy zdarzenie miało charakter domowy (BIT)
District	Numer dystryktu policyjnego
Latitude / Longitude	Współrzędne geograficzne

Tabela 1: Wybrane kolumny zbioru Chicago Crime

	CrimeKey	FullDate	PrimaryType	Arrest	Domestic
1	206	2026-04-02	CRIMINAL TRESPASS	0	0
2	207	2026-04-02	BURGLARY	0	0
3	208	2026-04-02	MOTOR VEHICLE THEFT	0	0
4	209	2026-04-02	BURGLARY	0	0
5	210	2026-04-02	DECEPTIVE PRACTICE	0	0
6	211	2026-04-02	ASSAULT	0	0
7	212	2026-04-02	ASSAULT	0	1
8	213	2026-04-02	THEFT	0	0
9	214	2026-04-02	BATTERY	0	0
10	215	2026-04-02	OTHER OFFENSE	0	0
11	216	2026-04-02	BATTERY	1	0
12	217	2026-04-02	THEFT	0	0
13	218	2026-04-02	BATTERY	0	1
14	219	2026-04-02	THEFT	0	0
15	220	2026-04-02	MOTOR VEHICLE THEFT	0	0
16	221	2026-04-02	MOTOR VEHICLE THEFT	0	0
17	222	2026-04-02	BURGLARY	0	0
18	223	2026-04-02	MOTOR VEHICLE THEFT	0	0
19	224	2026-04-02	MOTOR VEHICLE THEFT	0	0
20	225	2026-04-02	BURGLARY	0	0


Rysunek 1: Fragment surowych danych wejściowych

Rysunek 2: Schemat gwiazdy hurtowni danych *ChicagoCrime_DW*

3 ETL


Proces ETL został zrealizowany w SQL Server Integration Services. Zaimplementowano 5 przepływów odpowiedzialnych za załadowanie danych do hurtowni.

3.1 ETL 1 – DimDate



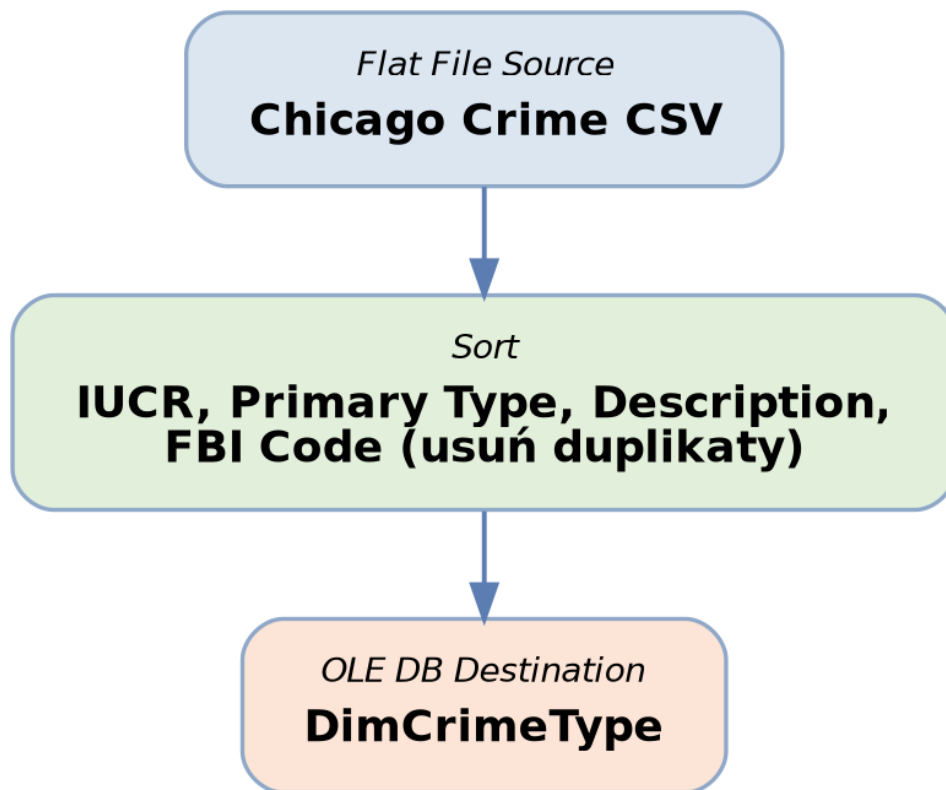
Rysunek 3: Przepływ ETL dla wymiaru DimDate

3.2 ETL 2 – DimLocation




Rysunek 4: Przepływ ETL dla wymiaru DimLocation

3.3 ETL 3 – DimCrimeType




Rysunek 5: Przepływ ETL dla wymiaru DimCrimeType

3.4 ETL 4 – DimLocationType

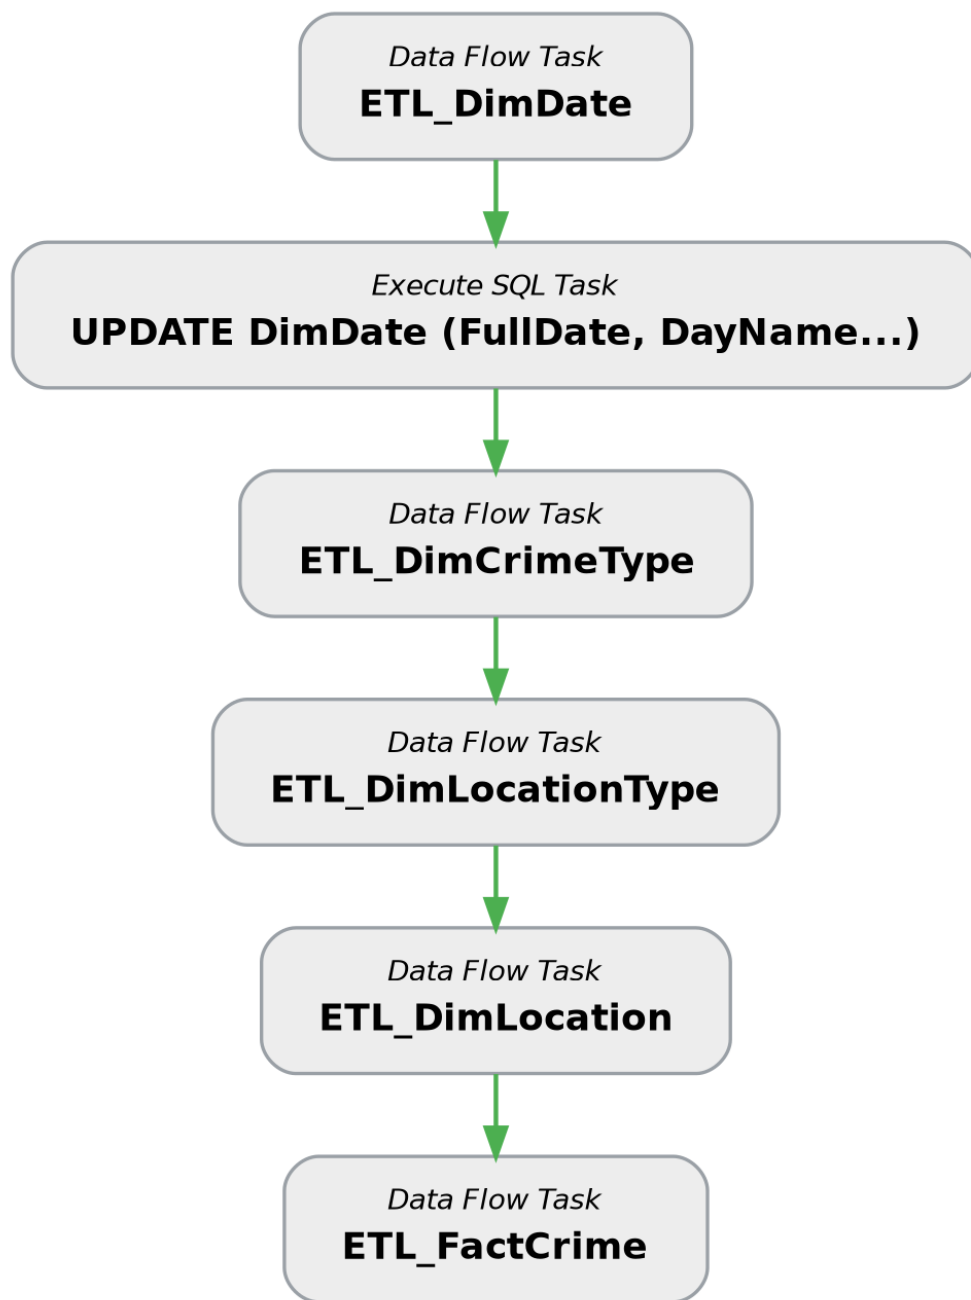


Rysunek 6: Przepływ ETL dla wymiaru DimLocationType

3.5 Execute SQL Task – finalny przepływ danych



Rysunek 7: Przepływ ETL ładujący tabelę faktów FactCrime



Rysunek 8: Kompletny przepływ ETL projektu

4 Kostka OLAP

Kostka OLAP została zbudowana w środowisku SQL Server Analysis Services w trybie Multidimensional. Zawiera 3 miary podstawowe oraz 4 miary obliczane (Calculated Members).

Miary podstawowe

Miara	Opis	Agregacja
Fact Crime Count	Liczba przestępstw	Count
Arrest	Liczba aresztowań	Sum
Domestic	Liczba przestępstw domowych	Sum

Tabela 2: Miary podstawowe w kostce OLAP

Z uwagi na fakt, że kolumny **Arrest** i **Domestic** są typu BIT i nie podlegają agregacji **Sum**, w widoku DSV utworzono Named Calculations **ArrestInt** oraz **DomesticInt** z konwersją **CAST AS INT**.

Miary obliczane (Calculated Members)

Miara	Wzór	Wartość
Arrest Rate	[Arrest] / [Fact Crime Count]	13,57%
Domestic Rate	[Domestic] / [Fact Crime Count]	18,42%
Theft Rate	SUM(FILTER po NAME) / [Fact Crime Count]	22,81%
Daily Crime Average	[Fact Crime Count] / liczba dni	2 739


Tabela 3: Miary obliczane

```

1 CREATE MEMBER CURRENTCUBE.[Measures].[Arrest Rate]
2 AS [Measures].[Arrest] / [Measures].[Fact Crime Count],
3 FORMAT_STRING = "0.00",
4 VISIBLE = 1;

```

Listing 1: Przykładowa formuła MDX – Arrest Rate



Rysunek 9: Struktura kostki OLAP

This screenshot shows the 'Edit Named Calculation' dialog box for the **ArrestInt** calculation. The 'Column name' field contains 'ArrestInt'. The 'Description' field is empty. The 'Expression' field contains the formula `CAST(Arrest AS INT)`. At the bottom, there are 'OK', 'Cancel', and 'Help' buttons.

(a) ArrestInt

This screenshot shows the 'Edit Named Calculation' dialog box for the **DomesticInt** calculation. The 'Column name' field contains 'DomesticInt'. The 'Description' field is empty. The 'Expression' field contains the formula `CAST(Domestic AS INT)`. At the bottom, there are 'OK', 'Cancel', and 'Help' buttons.


(b) DomesticInt

Rysunek 10: Named Calculations **ArrestInt** i **DomesticInt** w widoku DSV (konwersja `CAST AS INT`)

4.1 Hierarchie

W wymiarach zdefiniowano hierarchie użytkownika wspierające drażnienie danych (drill-down):

- **DimDate** – hierarchia *Kalendarz*: Year → Quarter → Month → Day
- **DimLocation** – hierarchia *Geography*: District → Ward → Community Area → Beat

(a) Hierarchia *Kalendarz* (DimDate)(b) Hierarchia *Geography* (DimLocation)

Rysunek 11: Hierarchie użytkownika w wymiarach

Year	Arrest Rate
2022	11,4829913147139
2023	12,2223361550702
2024	13,8286949473115
2025	15,9957627118644
2026	15,5489018173549

Rysunek 12: Przeglądanie kostki – miary obliczane w działaniu

5 Scenariusze – KPI

W kostce zdefiniowano 5 kluczowych wskaźników wydajności (KPI) z różnymi typami wizualizacji statusu.

5.1 Scenariusz 1 – Arrest Effectiveness

Cel biznesowy: Monitorowanie skuteczności aresztowań względem zarejestrowanych przestępstw.

Wartość: [Measures].[Arrest Rate]

Cel: $\geq 15\%$

Status: Gauge (wskaźnik zegarowy)

```

1 CASE
2   WHEN KpiValue("Arrest Effectiveness") >= KpiGoal("Arrest Effectiveness") THEN 1
3   WHEN KpiValue("Arrest Effectiveness") >= KpiGoal("Arrest Effectiveness") * 0.7 THEN 0
4   ELSE -1
5 END

```

Listing 2: Wyrażenie statusu KPI

The screenshot shows a configuration window for a KPI named 'Arrest Effectiveness'. The 'Associated measure group' is set to 'Fact Crime'. The 'Value Expression' is '[Measures].[Arrest Rate]'. The 'Goal Expression' is '15'. The 'Status' section shows a 'Gauge' indicator and a 'Status expression' that is a CASE statement: 'CASE WHEN KpiValue("Arrest Effectiveness") >= KpiGoal("Arrest Effectiveness") THEN 1 WHEN KpiValue("Arrest Effectiveness") >= KpiGoal("Arrest Effectiveness") * 0.7 THEN 0 ELSE -1 END'. The 'Trend' section shows a 'Standard arrow' indicator and a 'Trend expression' of '0'. There is an 'Additional Properties' section at the bottom.

Rysunek 13: Wizualizacja KPI Arrest Effectiveness

5.2 Scenariusz 2 – Domestic Violence Watch

Cel biznesowy: Monitorowanie udziału przestępstw o charakterze domowym.

Wartość: [Measures].[Domestic Rate]
Cel: $\leq 20\%$
Status: Traffic Light

The screenshot shows a KPI configuration window for 'Domestic Violence Watch'. The interface includes several sections: 'Name' (Domestic Violence Watch), 'Associated measure group' (Fact Crime), 'Value Expression' ([Measures].[Domestic Rate]), 'Goal Expression' (20), 'Status' (Traffic light), 'Status expression' (a CASE statement), 'Trend' (Standard arrow), and 'Trend expression' (0). The 'Status expression' section contains a SQL CASE statement:

```
CASE
WHEN KpiValue("Domestic Violence Watch") <= KpiGoal("Domestic Violence Watch") THEN 1
WHEN KpiValue("Domestic Violence Watch") <= KpiGoal("Domestic Violence Watch") * 1.2 THEN 0
ELSE -1
END
```

Rysunek 14: Wizualizacja KPI Domestic Violence Watch

5.3 Scenariusz 3 – Crime Volume Annual

Cel biznesowy: Kontrola rocznego wolumenu przestępstw.

Wartość: [Measures].[Fact Crime Count]

Cel: $\leq 250\,000$

Status: Traffic Light

The image shows a configuration window for a KPI named 'Crime Volume Annual'. The interface includes several sections:

- Name:** A text field containing 'Crime Volume Annual'.
- Associated measure group:** A dropdown menu set to 'Fact Crime'.
- Value Expression:** A text area containing the expression `[Measures].[Fact Crime Count]`.
- Goal Expression:** A text area containing the value `250000`.
- Status:**
 - Status indicator:** A dropdown menu showing a traffic light icon and the text 'Traffic light'.
 - Status expression:** A text area containing a SQL CASE statement:


```
CASE
WHEN KpiValue("Crime Volume Annual") <= KpiGoal("Crime Volume Annual") THEN 1
WHEN KpiValue("Crime Volume Annual") <= KpiGoal("Crime Volume Annual") * 1.5 THEN 0
ELSE -1
END
```
- Trend:**
 - Trend indicator:** A dropdown menu showing an upward arrow icon and the text 'Standard arrow'.
 - Trend expression:** A text area containing the value `0`.
- Additional Properties:** A collapsed section at the bottom.

Rysunek 15: Wizualizacja KPI Crime Volume Annual

5.4 Scenariusz 4 – Theft Rate / Theft Dominance

Cel biznesowy: Monitorowanie dominacji kradzieży w strukturze przestępczości.

Wartość: `[Measures].[Theft Rate]`

Cel: $\leq 25\%$

Status: Gauge

The screenshot shows a configuration window for a KPI named 'Theft Rate'. The interface is organized into several sections:

- KPI Section:**
 - Name:** A text field containing 'Theft Rate'.
 - Associated measure group:** A dropdown menu with 'Fact Crime' selected.
- Value Expression:** A text area containing the expression `[Measures].[Theft Rate]`.
- Goal Expression:** A text area containing the value '25'.
- Status Section:**
 - Status indicator:** A dropdown menu with a traffic light icon and the text 'Traffic light'.
 - Status expression:** A text area containing a SQL CASE statement:


```
CASE
  WHEN KpiValue("Theft Rate") <= KpiGoal("Theft Rate") THEN 1
  WHEN KpiValue("Theft Rate") <= KpiGoal("Theft Rate") * 1.2 THEN 0
  ELSE -1
END
```
- Trend Section:**
 - Trend indicator:** A dropdown menu with an upward arrow icon and the text 'Standard arrow'.
 - Trend expression:** A text area containing the value '0'.
- Additional Properties:** A collapsed section at the bottom.

Rysunek 16: Wizualizacja KPI Theft Rate (wskaźnik typu Gauge)

5.5 Scenariusz 5 – Daily Crime Load

Cel biznesowy: Kontrola średniego dziennego obciążenia przestępczością.

Wartość: `[Measures].[Daily Crime Average]`

Cel: ≤ 700

Status: Traffic Light

The image shows a configuration window for a KPI named 'Daily Crime Load'. The interface includes several sections:

- KPI:**
 - Name:
 - Associated measure group:
- Value Expression:**
- Goal Expression:**
- Status:**
 - Status indicator:
 - Status expression:

```
CASE
WHEN KpiValue("Daily Crime Load") <= KpiGoal("Daily Crime Load") THEN 1
WHEN KpiValue("Daily Crime Load") <= KpiGoal("Daily Crime Load") * 1.3 THEN 0
ELSE -1
END
```
- Trend:**
 - Trend indicator:
 - Trend expression:
- Additional Properties:** (collapsed)


Rysunek 17: Wizualizacja KPI Daily Crime Load

6 Data Mining


Zaimplementowano 4 modele Data Mining w ramach struktury `MiningStructureCrime`. Trzy modele predykcyjne (Decision Trees, Neural Network, Naive Bayes) prognozują wartość atrybutu `Arrest`, natomiast model Microsoft Clustering realizuje segmentację przestępstw na 10 naturalnych klastrów.

6.1 Drzewo decyzyjne (DT_Arrest)

Algorytm Microsoft Decision Trees buduje drzewo na podstawie atrybutów wejściowych. Najsilniejszymi predyktorami okazały się `PrimaryType` oraz `LocationType`.




Rysunek 18: Wizualizacja drzewa decyzyjnego




Rysunek 19: Sieć zależności atrybutów

6.2 Sieć neuronowa (NN_Arrest)




Rysunek 20: Neural Network Viewer – model NN_Arrest


6.3 Naive Bayes (NB_Arrest)



Rysunek 21: Naive Bayes – Attribute Profiles



Rysunek 22: Naive Bayes – Attribute Characteristics




Rysunek 23: Naive Bayes – Attribute Discrimination

6.4 Klastrowanie (Clustering_Crime)


Algorytm Microsoft Clustering pogrupował przestępstwa w 10 klastrów. Każdy klaster opisuje charakterystyczny profil przestępstwa.

Klaster	Charakterystyka
Weekday_Street_VehicleTheft_LowArrest	ulica, kradzież pojazdów/mienia, dni robocze, arrest 5%
Weekend_Street_VehicleTheft	ulica, kradzież pojazdów/uszkodzenia, weekend, arrest 16%
Weekday_Domestic_Battery	BATTERY 54%, domowe 90%, mieszkania, arrest 14%
Weekday_Downtown_RetailTheft	THEFT 63%, sklepy/centrum, dni robocze, arrest 14%
Weekday_Residential_Fraud_LowArrest	DECEPTIVE PRACTICE 42%, mieszkania, arrest 4%
Weekday_Westside_HighArrest	dystrykt 11 (zachód), wysoki arrest 38%
Weekend_Domestic_Violence	BATTERY 45%, domowe 69%, weekend, arrest 13%
Weekend_Retail_Theft	THEFT 49%, handel, weekend, arrest 11%
Weekday_Street_Battery_Assault	BATTERY 46%/ASSAULT 19%, chodniki, arrest 19%
Weekday_Apartment_MixedCrime	APARTMENT 73%, mieszane (kradzież/uszkodzenia), arrest 8%

Tabela 4: Opisowe nazwy klastrów



Rysunek 24: Diagram klastrów




Rysunek 25: Profile klastrów (Cluster Profiles / Characteristics)

6.5 Porównanie modeli

Wykres Lift Chart przedstawia porównanie skuteczności wszystkich modeli predykcyjnych.

Model	Score
DT_Arrest	0,96
NN_Arrest	0,95
NB_Arrest	0,95
Clustering_Crime	0,91
Ideal Model	1,00

Tabela 5: Wyniki modeli na wykresie Lift Chart



Rysunek 26: Lift Chart – porównanie modeli

Uwaga metodologiczna: Klasy w zbiorze są mocno niebalansowane (86% bez aresztu / 14% z aresztem), co oznacza, że „prosty” model przewidujący zawsze brak aresztu osiągnąłby już 86% trafności. Wysokie wartości Score wszystkich modeli wynikają częściowo z tej charakterystyki danych – realna zdolność wykrywania klasy mniejszościowej (Arrest=1) jest niższa.


7 Model tabelaryczny (SSAS Tabular)

Równoległe do kostki wielowymiarowej zbudowano model tabelaryczny w osobnej instancji SSAS w trybie Tabular. Zaimportowano tabelę faktów **FactCrime**, cztery wymiary oraz cztery tabele predykcji (**dt_arrest**, **nn_arrest**, **nb_arrest**, **clusters_prediction**); relacje utworzono po kluczach.

Miary DAX

Miara	Opis	Wartość
Total Crimes	Liczba przestępstw	~1 000 000
Arrest Rate	Współczynnik aresztowań	13,57%
Domestic Rate	Współczynnik przestępstw domowych	18,42%
Daily Crime Avg	Średnia dzienna liczba przestępstw	685

Tabela 6: Miary DAX w modelu tabelarycznym




Rysunek 27: Diagram relacji modelu tabelarycznego

Year	Total Crimes	Arrest Rate	Domestic Rate	Daily Crime Avg
2022	187904	0,114829913147139	0,181763027929155	693,372693726937
2023	263313	0,122223361550702	0,178821402665269	721,405479452055
2024	259070	0,138286949473115	0,183703246226888	707,841530054645
2025	236944	0,159957627118644	0,190450064150179	649,161643835616
2026	52769	0,155489018173549	0,193977524683053	567,408602150538


Rysunek 28: Przeglądanie modelu tabelarycznego (Browse) w SSMS

8 Wizualizacja danych – Power BI

Wizualizacja zebranych danych została zrealizowana w narzędziu Power BI Desktop. Przygotowano dwa raporty: pierwszy oparty na połączeniu Live Connection do kostki wielowymiarowej SSAS (wskaźniki KPI oraz analiza geograficzna), drugi na imporcie danych z hurtowni relacyjnej ChicagoCrime_DW (miary DAX oraz analiza czasowa z prognozą i drzewem dekompozycji).




Rysunek 29: Połączenie Power BI z SSAS




Rysunek 30: Widok modelu w Power BI – relacje między tabelą faktów, wymiarami i tabelami predykcji (raport relacyjny)

8.1 Raport 1 – KPI Dashboard




Rysunek 31: Raport KPI Dashboard (Live do kostki OLAP)

8.2 Raport 2 – Geografia przestępczości




Rysunek 32: Geografia – liczba przestępstw wg dystryktu, słupki kolorowane wg Arrest Rate




Rysunek 33: Geografia – mapa choropletowa dystryktów policyjnych Chicago

8.3 Raport 3 – Analiza relacyjna (import z hurtowni)


Drugi raport zbudowano na imporcie danych z hurtowni ChicagoCrime_DW. Tryb importu (zamiast Live) był konieczny, ponieważ linia trendu i prognoza nie działają na połączeniu Live do kostki wielowymiarowej (oś czasu jest tam dyskretna).



Rysunek 34: Współczynnik aresztowań wg typu przestępstwa oraz liczba przestępstw wg dnia tygodnia



Rysunek 35: Liczba przestępstw wg daty – linia trendu oraz prognoza



Rysunek 36: Drzewo dekompozycji współczynnika aresztowań

9 Podsumowanie

Projekt obejmuje pełen cykl przetwarzania danych: od ich przygotowania przez proces ETL, przez budowę hurtowni danych w schemacie gwiazdy, implementację kostki OLAP z miarami obliczanymi i wskaźnikami KPI, analizę z wykorzystaniem czterech algorytmów Data Mining, po zaawansowaną wizualizację wyników w Power BI.

Dzięki zastosowanym narzędziom możliwe było przeprowadzenie kompleksowej analizy ponad miliona rekordów dotyczących przestępczości miasta Chicago. Uzyskane wyniki dostarczyły wartościowych wniosków na temat skuteczności aresztowań, rozkładu przestępczości w czasie i przestrzeni oraz naturalnych segmentów przestępstw.

Realizacja projektu pozwoliła na zdobycie praktycznego doświadczenia w pracy z narzędziami klasy Business Intelligence – SQL Server Integration Services, Analysis Services Multidimensional oraz Power BI – co stanowi kluczowy zestaw kompetencji w obszarze analizy danych.